

Hausa Ajami OCR Dataset

Ce dataset contient des paires image/transcription de manuscrits haoussa en écriture ajami (écriture arabe adaptée au haoussa).

Contenu

Chaque ligne du fichier `data/train/metadata.jsonl` correspond à une ligne de texte ajami segmentée, avec :

- `file_name` : nom du fichier image correspondant (image de la ligne, recadrée)
- `transcript` : translittération en écriture latine de la ligne
- `source` : identifiant du manuscrit d'origine (voir tableau ci-dessous)

Sources des manuscrits

Le champ `source` fait référence à l'un des manuscrits suivants :

ID source	Titre du manuscrit	Auteur / Copiste	Notes
1	The Glorious (Majidu): Infiraji 1	Alhaji Malam Aliyu Namangi (auteur), Ibrahim Yaqubu Gusau (copiste)	Poème d'éloge du Prophète Muhammad, fait partie de la collection Infiraji (9 poèmes)
2	Warning (Gargadi): Infiraji 2	Alhaji Aliyu Namangi (auteur), Ibrahim Yaqubu Gusau (copiste)	Avertissement sur le caractère éphémère de la vie, distribué par Gaskiya Corporation, Zaria
15	A Poem in Honor of the Emir of Kano (Wakar Sarkin Kano)	Abd al-Wahhab Adam al-Falaki (auteur), Umar Falke (propriétaire)	Éloge de l'Émir de Kano Abdullahi Bayero (1881-1953), source : African Ajami Library / Northwestern University Libraries
16	Eulogy for Ahmad Tijani (Yabo ga Ahmad Tijani)	Auteur inconnu, Umar Falke (propriétaire)	Éloge soufi du cheikh Ahmad Tijani, fondateur de la Tijaniyya, source : African Ajami Library / Northwestern University Libraries
18	Birth Record & Building Contract (Rajistar Haihuwa & Kwangilar Gina Gidaje)	Malam Muhammad Awwal Shendam	Deux documents : acte de naissance et contrat de construction, exemples d'usage pratique de l'ajami haoussa pour la vie quotidienne

Ce tableau sera complété à mesure que de nouveaux manuscrits seront ajoutés au dataset.

Sources externes citées

Certains manuscrits proviennent de l'**African Ajami Library** (Boston University / Northwestern University Libraries), dans le cadre du projet *Ajami Literacy and the Expansion of Literacy and Islam in West Africa* (NEH). Ces matériaux sont soumis à copyright et distribués sous licence **Creative Commons Attribution-Non-Commercial 4.0**, qui permet l'usage, la distribution et la reproduction non commerciale, à condition de créditer l'auteur original et la source. Pour tout usage au-delà de ces conditions, contacter le Pr. Fallou Ngom (fngom@bu.edu).

Référence complète : Ngom, Fallou, Jennifer Yanco, Mustapha Hashim Kurfi, Garba Zakari, Babacar Dieng, Daivi Rodima-Taylor et Rebecca Shereikis. 2022. *African Ajami Library*. Boston University.
<https://sites.bu.edu/nehajami/>

Convention de translittération

- Consonnes glottalisées haoussa notées selon l'orthographe boko standard : **ɗ, ƙ, ɓ**
- Emprunts arabes (vocabulaire religieux) translittérés avec macrons et signes diacritiques scientifiques (ex. **ā, ī, ū, ʿ, š, ḥ**)
- Hamza notée par une apostrophe simple **'**
- Les tons et la longueur vocalique du haoussa courant ne sont pas systématiquement notés dans cette version

Segmentation

La segmentation actuelle est faite au niveau de la ligne et du mot. La segmentation au niveau de la lettre n'est pas encore disponible dans cette version du dataset.

Contributeurs

Dataset réalisé dans le cadre du projet AjamiXTranslit (Université d'Orléans).